



中山大學
SUN YAT-SEN UNIVERSITY

阵列信号处理 第五讲

授课教师：段克清

授课单位：电子与通信工程学院

电子邮箱：duankq@mail.sysu.edu.cn

联系电话：XXXXXXXXXXXXX（同微信）



本次课内容

1. 最大似然 (ML) 法
2. 空间平滑法去相干



本次课内容

1. 最大似然 (ML) 法
2. 空间平滑法去相干



相关数学知识

概率 (Probability) 和统计 (Statistics)

概率问题： 已知一个模型和参数，如何去预测模型产生的**结果**。

比如： 研究如何养猪（**模型是猪**），选好了品种、喂养方式和猪棚环境等（**选择参数**），我想预测养出来的猪大概有多肥，肉质如何（**预测结果**）

✓ **概率是在已知模型的基础上，对其他样本数据进行预测。**



统计问题：有一堆数据，利用这堆数据估计模型和参数。

比如：买了一堆肉，通过观察判断认定是猪肉（**确定模型**，实际工程中通过观察数据推测模型为高斯分布、指数分布等），然后进一步研究判定猪的品种、圈养猪还是网易猪等（**推测模型参数**）。

✓ **统计是在已知数据的前提下，进行模型的归纳与推断。**



Lary Wasserman 在 《All of Statistics》 的序言里有说过：



Statistics: Given the information in your hand, what is in the pails?



Probability: Given the information in the pail, what is in your hand?



似然 (likelihood) 函数

似然和概率意思相近。字典上的解释：

The likelihood of something happening is how likely it is to happen.

对于函数 $P(x|\theta)$, x 表示具体数据, θ 表示模型的参数。

- 如果 θ 已知, x 未知, 该函数为概率函数 (probability function) , 表示对于不同观测数据 x 出现的概率;
- 如果 x 已知, θ 未知, 该函数为似然函数 (likelihood function) , 表示对于不同模型参数, 出现 x 数据的概率。



最大似然估计 (Maximum Likelihood Estimation, MLE)

给定观测数据，评估模型参数！

例：统计全国人口身高。首先假设身高服从正态分布，但均值和方差未知。通过采样，获取部分人身高，然后利用**最大似然估计**来获取上述正态分布中均值和方差。

首先，假设 x_1, x_2, \dots, x_n 为独立同分布采样， θ 为模型参数， f 为所采用模型，则在参数为 θ 情况下采样发生的概率为：

$$f(x_1, x_2, \dots, x_n | \theta) = f(x_1 | \theta) \times f(x_2 | \theta) \times \dots \times f(x_n | \theta)$$



$$f(x_1, x_2, \dots, x_n | \theta) = f(x_1 | \theta) \times f(x_2 | \theta) \times \dots \times f(x_n | \theta)$$

此时, x_1, x_2, \dots, x_n 已知, θ 未知, 故似然函数定义为:

$$L(\theta | x_1, x_2, \dots, x_n) = f(x_1, x_2, \dots, x_n | \theta) = \prod_{i=1}^n f(x_i | \theta)$$

实际应用中, 往往两边取对数, 得到对数似然:

$$\ln L(\theta | x_1, x_2, \dots, x_n) = \ln \left[\prod_{i=1}^n f(x_i | \theta) \right]$$

所谓最大似然即为最大对数似然, 即 $\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta | x_1, x_2, \dots, x_n)$



例题： 设 $x \sim N(\mu, \sigma^2)$, μ 和 σ 为未知参数, x_1, x_2, \dots, x_n 为对应样本, 求 μ 和 σ 的最大似然估计。

解： x 的概率密度为 $f(x_i | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}}$


其似然函数为 $\ln L(\mu, \sigma^2 | x) = \ln \left[\prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right]$

取对数，得 $\ln L(\mu, \sigma^2 | x) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$



求偏导可得:

$$\begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2 | x) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2 | x) = 0 \end{cases}$$



$$\begin{aligned} \hat{\mu} &= \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \hat{\sigma}^2 &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{aligned}$$



高斯随机变量 $x \sim N(\mu, \sigma^2)$

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

高斯随机向量 $\mathbf{x} \sim N(\bar{\mathbf{x}}, \Gamma_{\mathbf{x}})$

$\Gamma_{\mathbf{x}}$ 为 \mathbf{x} 自协方差矩阵

$$f(\mathbf{x}) = \frac{1}{(2\pi)^{m/2} |\Gamma_{\mathbf{x}}|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \bar{\mathbf{x}})^T \Gamma_{\mathbf{x}}^{-1} (\mathbf{x} - \bar{\mathbf{x}})\right]$$

复高斯随机向量 $\mathbf{x} \sim CN(\boldsymbol{\mu}_{\mathbf{x}}, \Gamma_{\mathbf{x}})$

$$f(\mathbf{x}) = \frac{1}{\pi^m |\Gamma_{\mathbf{x}}|} \exp\left[-(\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}})^H \Gamma_{\mathbf{x}}^{-1} (\mathbf{x} - \boldsymbol{\mu}_{\mathbf{x}})\right]$$

矩阵分析与应用

P41 12/44



最大似然法空间谱估计基本原理: $\mathbf{x}(n) = \mathbf{A}(\theta)\mathbf{s}(n) + \mathbf{n}(n)$

模型已知, 即噪声为复平稳高斯白噪声, 可得

$$\boldsymbol{\mu}_{\mathbf{x}} = E\{\mathbf{x}(n)\} = \mathbf{A}(\theta)\mathbf{s}(n)$$

$$\begin{aligned}\boldsymbol{\Gamma}_{\mathbf{x}} &= E\left\{\left[\mathbf{x}(n) - \boldsymbol{\mu}_{\mathbf{x}}\right]\left[\mathbf{x}(n) - \boldsymbol{\mu}_{\mathbf{x}}\right]^{\mathrm{H}}\right\} \\ &= E\left\{\left[\mathbf{A}(\theta)\mathbf{s}(n) + \mathbf{n}(n) - \boldsymbol{\mu}_{\mathbf{x}}\right]\left[\mathbf{A}(\theta)\mathbf{s}(n) + \mathbf{n}(n) - \boldsymbol{\mu}_{\mathbf{x}}\right]^{\mathrm{H}}\right\} \\ &= E\left\{\mathbf{n}(n)\mathbf{n}^{\mathrm{H}}(n)\right\} \\ &= \sigma_{\mathrm{N}}^2 \mathbf{I}\end{aligned}$$

矩阵分析与应用

P43

13/44



L 次采样（快拍）联合概率密度函数为

γ 为所有参数集合

$$\begin{aligned} f\{\mathbf{x}(1), \mathbf{x}(2), \dots, \mathbf{x}(L) | \gamma\} &= \prod_{n=1}^L \frac{1}{\pi^M |\mathbf{\Gamma}_{\mathbf{x}}|} \exp\left[-(\mathbf{x}(n) - \boldsymbol{\mu}_{\mathbf{x}})^H \mathbf{\Gamma}_{\mathbf{x}}^{-1} (\mathbf{x}(n) - \boldsymbol{\mu}_{\mathbf{x}})\right] \\ &= \prod_{n=1}^L \frac{1}{(\pi \sigma_N^2)^M} \exp\left[-|\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2 / \sigma_N^2\right] \end{aligned}$$

取对数 $L[\theta, \sigma_N^2, \mathbf{s}(n)] = \ln f\{\mathbf{x}(1), \mathbf{x}(2), \dots, \mathbf{x}(L) | \gamma\}$

$$\begin{aligned} &= \ln \left\{ \prod_{n=1}^L \frac{1}{(\pi \sigma_N^2)^M} \exp\left[-|\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2 / \sigma_N^2\right] \right\} \\ &= -ML \ln \sigma_N^2 - \frac{1}{\sigma_N^2} \sum_{n=1}^L |\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2 \end{aligned}$$



$$L[\theta, \sigma_N^2, \mathbf{s}(n)] = -ML \ln \sigma_N^2 - \frac{1}{\sigma_N^2} \sum_{n=1}^L |\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2$$

先估计 σ_N^2 使似然函数最大，得：

$$\hat{\sigma}_N^2 = \frac{1}{ML} \sum_{n=1}^L |\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2$$

代入原似然函数：

$$\max_{\theta, \mathbf{s}(n)} \left[-ML \ln \frac{1}{ML} \sum_{n=1}^L |\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2 \right]$$

先固定 θ 估计 $\mathbf{s}(n)$

$$\hat{\mathbf{s}}(n) = [\mathbf{A}^H(\theta) \mathbf{A}(\theta)]^{-1} \mathbf{A}^H(\theta) \mathbf{x}(n) \quad n = 1, 2, \dots, N$$



$$\max_{\theta, \mathbf{s}(n)} \left[-ML \ln \frac{1}{ML} \sum_{n=1}^L |\mathbf{x}(n) - \mathbf{A}(\theta) \mathbf{s}(n)|^2 \right]$$

$$\hat{\mathbf{s}}(n) = [\mathbf{A}^H(\theta) \mathbf{A}(\theta)]^{-1} \mathbf{A}^H(\theta) \mathbf{x}(n) \quad n = 1, 2, \dots, N$$

将 $\hat{\mathbf{s}}(n)$ 代回似然函数，求关于 θ 的估计。

$$\min_{\theta} \left[\frac{1}{ML} \sum_{n=1}^L |\mathbf{x}(n) - \mathbf{A}(\theta) \hat{\mathbf{s}}(n)|^2 \right]$$

$$\min_{\theta} \left[\frac{1}{ML} \sum_{n=1}^L \left| \mathbf{x}(n) - \mathbf{A}(\theta) [\mathbf{A}^H(\theta) \mathbf{A}(\theta)]^{-1} \mathbf{A}^H(\theta) \mathbf{x}(n) \right|^2 \right]$$



化简为:

$$\begin{aligned} & \frac{1}{ML} \sum_{n=1}^L \left| \mathbf{x}(n) - \mathbf{A}(\theta) [\mathbf{A}^H(\theta) \mathbf{A}(\theta)]^{-1} \mathbf{A}^H(\theta) \mathbf{x}(n) \right|^2 \\ &= \frac{1}{ML} \sum_{n=1}^L \left| (\mathbf{I} - \mathbf{P}_A) \mathbf{x}(n) \right|^2 \\ &= \frac{1}{ML} \sum_{n=1}^L \left| \mathbf{P}_A^\perp \mathbf{x}(n) \right|^2 \\ &= \frac{1}{ML} \sum_{n=1}^L \mathbf{x}^H(n) \mathbf{P}_A^\perp \mathbf{x}(n) \\ &= \frac{1}{ML} \sum_{n=1}^L \text{tr} \left[\mathbf{P}_A^\perp \mathbf{x}(n) \mathbf{x}^H(n) \right] \\ &= \frac{1}{M} \text{tr} \left\{ \mathbf{P}_A^\perp \sum_{n=1}^L \frac{1}{L} \left[\mathbf{x}(n) \mathbf{x}^H(n) \right] \right\} \\ &= \frac{1}{M} \text{tr} \left\{ \mathbf{P}_A^\perp \hat{\mathbf{R}} \right\} \end{aligned}$$

投影矩阵: $\mathbf{P}_A = \mathbf{A}(\theta) [\mathbf{A}^H(\theta) \mathbf{A}(\theta)]^{-1} \mathbf{A}^H(\theta)$

正交投影矩阵: $\mathbf{P}_A^\perp = \mathbf{I} - \mathbf{P}_A$

} $\mathbf{x}^H \mathbf{y} = \text{tr}(\mathbf{y} \mathbf{x}^H)$ 向量内积=矩阵的迹

$$\hat{\mathbf{R}} = \sum_{n=1}^L \frac{1}{L} \left[\mathbf{x}(n) \mathbf{x}^H(n) \right]$$



因此，求 $\min_{\theta} \text{tr} \left\{ \mathbf{P}_A^{\perp} \hat{\mathbf{R}} \right\}$ 或 $\max_{\theta} \text{tr} \left\{ \mathbf{P}_A \hat{\mathbf{R}} \right\}$ $\theta = \{\theta_1, \theta_2, \dots, \theta_p\}$


数学意义： P 维寻优

$$\hat{\mathbf{R}} = \sum_{n=1}^L \frac{1}{L} [\mathbf{x}(n) \mathbf{x}^H(n)]$$

物理意义：搜索 P 维信号子空间去拟合阵列数据 $\mathbf{x}(n) \quad n = 1, 2, \dots, N$

使得投影误差最小

几何意义：





特例：单个信号源情况

$$\mathbf{x}(n) = \mathbf{a}(\theta)\mathbf{s}(n) + \mathbf{n}(n)$$

$$\mathbf{P}_A = \mathbf{a}(\theta) \left[\mathbf{a}^H(\theta) \mathbf{a}(\theta) \right]^{-1} \mathbf{a}^H(\theta) = \frac{\mathbf{a}(\theta) \mathbf{a}^H(\theta)}{\mathbf{a}^H(\theta) \mathbf{a}(\theta)}$$


$$\max_{\theta} \left[\text{tr}(\mathbf{P}_A \hat{\mathbf{R}}) \right] = \max_{\theta} \left[\text{tr} \left(\frac{\mathbf{a}(\theta) \mathbf{a}^H(\theta)}{M} \hat{\mathbf{R}} \right) \right] = \max_{\theta} \left[\frac{\mathbf{a}^H(\theta) \hat{\mathbf{R}} \mathbf{a}(\theta)}{M} \right]$$

即常规波束扫描方法 (CBF)


一般多信源时，ML法涉及多维优化问题，计算量很大。



最大似然方法 ($M = 16 / d = \lambda/2$)



目标来向 $[10^\circ, 30^\circ]$



目标来向 $[10^\circ, 20^\circ]$



本次课内容

1. 最大似然 (ML) 法
2. 空间平滑法去相干



1. 相关性
2. 相干源问题
3. 空间平滑法
4. 空间平滑法去相关性能分析



高分辨空间谱估计多基于对阵列协方差特性的分析，阵列的协方差矩阵为：

$$\mathbf{R} = \mathbf{A}(\theta) \mathbf{R}_s \mathbf{A}^H(\theta) + \sigma_N^2 \mathbf{I}$$

- 若 S 由 P 个独立信源，则特征分解后可得到 P 个大特征值；
- 若 S 中部分信源相干，则特征分解后大特征值小于 P ，即相干信号合并为一个信号，从而导致所估信源数目减少；
- 原因是某些相干源的特征矢量不正交于噪声子空间，在空间谱曲线上不出现峰值，因此导致谱估计的漏报。



随机变量 x 、 y

相关系数 $\rho_{x,y} = E[xy^*] / \left\{ \sqrt{E[|x|^2]} \sqrt{E[|y|^2]} \right\}$

- 若 $\rho_{x,y} = 1 \Leftrightarrow x = cy$, 其中 c 为常数; 称 x 和 y 为完全相关或相干;
- 若 $\rho_{x,y} = 0$, 称 x 和 y 不相关;
- 若 $0 < |\rho_{x,y}| < 1$, 称 x 和 y 相关。




例：多径传播

$$s_2(t) = ks_1(t - \tau)$$

如果是窄带信号

$$s_1(t - \tau) = s_1(t) e^{j\varphi}$$

此时， $s_1(t)$ 和 $s_2(t)$ 相干。



对多径传播，各径分量间是否相干取决于信号带宽，当延迟时间

τ 大于相干时间 ($\tau_0 = 1/B$)，则不相干。



1. 相关性
2. 相干源问题
3. 空间平滑法
4. 空间平滑法去相关性能分析



以 $P = 2$ 为例

阵列信号 $\mathbf{x}(n) = \mathbf{A}(\theta) \begin{bmatrix} s_1(n) \\ s_2(n) \end{bmatrix} + \mathbf{n}(n)$

阵列相关矩阵 $\mathbf{R} = E[\mathbf{x}\mathbf{x}^H] = \mathbf{A}(\theta) E \begin{bmatrix} s_1 s_1^* & s_1 s_2^* \\ s_2 s_1^* & s_2 s_2^* \end{bmatrix} \mathbf{A}^H(\theta) + \sigma_N^2$

$$\mathbf{R}_S = \begin{bmatrix} \sigma_1^2 & \rho_{12} \sigma_1 \sigma_2 \\ \rho_{12}^* \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix}$$

$\sigma_1 : S_1$ 信号功率
 $\sigma_2 : S_2$ 信号功率

当 $|\rho_{12}| = 1$, \mathbf{R}_S 秩为 1, 秩亏损。



对任意 P , 如果 P 个信源完全相关 (相干) , 则 $\mathbf{R}_s = E[s(n)s^H(n)]$ 的秩为 1。

$$\mathbf{x}(n) = \mathbf{a}(\theta_1)s_1(n) + \mathbf{a}(\theta_2)s_2(n) + \mathbf{n}(n)$$

当 $|\rho_{12}| = 1$, 即 $s_1(n) = cs_2(n)$

$$\begin{aligned}\mathbf{x}(n) &= c\mathbf{a}(\theta_1)s_2(n) + \mathbf{a}(\theta_2)s_2(n) + \mathbf{n}(n) \\ &= [c\mathbf{a}(\theta_1) + \mathbf{a}(\theta_2)]s_2(n) + \mathbf{n}(n) \\ &= \mathbf{b}s_2(n) + \mathbf{n}(n)\end{aligned}$$

b: 称为广义阵列流形或广义导向矢量, 不对应某个DOA。


若无噪声: $\mathbf{x}(n) \in \text{span}(\mathbf{b})$



1. 相关性
2. 相干源问题
3. 空间平滑法
4. 空间平滑法去相关性能分析



M 元等距线阵分成 L 个 K 元子阵 $L = M - K + 1$



全阵时 $\mathbf{x}(n) = \mathbf{A}(\theta)\mathbf{s}(n) + \mathbf{n}(n)$

其中导向矢量 $\mathbf{a}(\theta) = \begin{bmatrix} 1 & e^{j\pi \sin \theta} & \dots & e^{j(M-1)\pi \sin \theta} \end{bmatrix}^T$



第一个子阵: $\mathbf{x}_1(n) = \mathbf{A}_K(\theta)\mathbf{s}(n) + \mathbf{n}_1(n)$

其导向矢量: $\mathbf{a}_K(\theta) = \begin{bmatrix} 1 & e^{j\pi \sin \theta} & \dots & e^{j(K-1)\pi \sin \theta} \end{bmatrix}^T$

第二个子阵: $\mathbf{x}_2(n) = \mathbf{A}_K(\theta)\mathbf{D}\mathbf{s}(n) + \mathbf{n}_2(n)$

$$\mathbf{D} = \begin{bmatrix} e^{j\pi \sin \theta_1} & & & 0 \\ & e^{j\pi \sin \theta_2} & & \\ & & \ddots & \\ 0 & & & e^{j\pi \sin \theta_P} \end{bmatrix}_{P \times P}$$



第 L 个子阵: $\mathbf{x}_L(n) = \mathbf{A}_K(\theta) \mathbf{D}^{L-1} \mathbf{s}(n) + \mathbf{n}_L(n)$

$$\mathbf{D}^m \mathbf{s}(n) = \begin{bmatrix} \mathbf{s}_1(n) e^{j\pi m \sin \theta_1} & \mathbf{s}_2(n) e^{j\pi m \sin \theta_2} & \cdots & \mathbf{s}_P(n) e^{j\pi m \sin \theta_P} \end{bmatrix}^T$$

若 $\mathbf{s}_1(n) = c\mathbf{s}_2(n)$ (相干源), 则采用这种方法后破坏了相关性。

通过多个子阵, 每个子阵相当于空间平移, 多出的旋转因子归并到信号包括 $\mathbf{s}_i(n)$ (不同信号由于方向不同, 旋转因子不同), 然后将各子阵数据在相关域平均。



第 1 个子阵: $\mathbf{x}_1(n) \Rightarrow \mathbf{R}_1 = E[\mathbf{x}_1(n)\mathbf{x}_1^H(n)] = \mathbf{A}_K \mathbf{R}_S \mathbf{A}_K^H + \sigma_N^2 \mathbf{I}$

第 2 个子阵: $\mathbf{x}_2(n) \Rightarrow \mathbf{R}_2 = E[\mathbf{x}_2(n)\mathbf{x}_2^H(n)] = \mathbf{A}_K \mathbf{D} \mathbf{R}_S \mathbf{D}^H \mathbf{A}_K^H + \sigma_N^2 \mathbf{I}$

第 L 个子阵: $\mathbf{x}_L(n) \Rightarrow \mathbf{R}_L = E[\mathbf{x}_L(n)\mathbf{x}_L^H(n)] = \mathbf{A}_K \mathbf{D}^{(L-1)} \mathbf{R}_S \mathbf{D}^{-(L-1)} \mathbf{A}_K^H + \sigma_N^2 \mathbf{I}$

空间平滑:
$$\begin{aligned} \tilde{\mathbf{R}}_L &= \frac{1}{L} \sum_{i=1}^L \mathbf{R}_i = \mathbf{A}_K \left[\frac{1}{L} \sum_{i=1}^L \mathbf{D}^{(i-1)} \mathbf{R}_S \mathbf{D}^{-(i-1)} \right] \mathbf{A}_K^H + \sigma_N^2 \mathbf{I} \\ &= \mathbf{A}_K \tilde{\mathbf{R}}_S \mathbf{A}_K^H + \sigma_N^2 \mathbf{I} \end{aligned}$$

将该矩阵进行特征分解，得到特征矢量用于各类子空间类DOA估计方法。



可以严格证明:

$$\tilde{\mathbf{R}}_S = \frac{1}{L} \sum_{i=1}^L \mathbf{D}^{(i-1)} \mathbf{R}_S \mathbf{D}^{-(i-1)}$$

如果 \mathbf{R}_S 无全零行, 对角阵 \mathbf{D} 的对角元素不两两相等, 则

$$\text{rank}(\tilde{\mathbf{R}}_S) \geq \min\{r + L - 1, P\}$$

其中 r 是 \mathbf{R}_S 的秩, P 是 \mathbf{R}_S 的维数。

可见最坏情况下 $r = 1$, 当 $L \geq P$, $\text{rank}(\tilde{\mathbf{R}}_S) = P$

直观上, 平滑次数 L 越大越好, 平滑去相关越好;

但是, 此时 K 减小, 分辨的信源数减小, 从而造成孔径损失。



空间平滑法去相干

$$\mathbf{R} = \mathbf{A}(\theta) E \begin{bmatrix} s_1 s_1^* & s_1 s_2^* \\ s_2 s_1^* & s_2 s_2^* \end{bmatrix} \mathbf{A}^H(\theta) + \sigma_N^2$$

$$\mathbf{R}_{S1} = \begin{bmatrix} \sigma_1^2 & \rho_{12} \sigma_1 \sigma_2 \\ \rho_{12}^* \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix} = \begin{bmatrix} \sigma_1 \sigma_1 & \sigma_2 \sigma_1 \\ \sigma_1 \sigma_2 & \sigma_2 \sigma_2 \end{bmatrix}$$

行列式为零



$$\mathbf{Ds}(n) = \begin{bmatrix} \mathbf{s}_1(n) e^{j\pi \sin \theta_1} & \mathbf{s}_2(n) e^{j\pi \sin \theta_2} \end{bmatrix}^T$$


$$\begin{aligned} \mathbf{R}_{S2} &= \begin{bmatrix} \sigma_1^2 & e^{j2\pi(\sin \theta_1 - \sin \theta_2)} \rho_{12} \sigma_1 \sigma_2 \\ e^{j2\pi(\sin \theta_2 - \sin \theta_1)} \rho_{12}^* \sigma_1 \sigma_2 & \sigma_2^2 \end{bmatrix} \\ &= \begin{bmatrix} \sigma_1 \sigma_1 & e^{j2\pi(\sin \theta_1 - \sin \theta_2)} \sigma_2 \sigma_1 \\ e^{j2\pi(\sin \theta_2 - \sin \theta_1)} \sigma_1 \sigma_2 & \sigma_2 \sigma_2 \end{bmatrix} \end{aligned}$$

行列式为零



$$\mathbf{R}_{S1} + \mathbf{R}_{S2} = \begin{bmatrix} 2\sigma_1\sigma_1 & \left(1 + e^{j2\pi(\sin\theta_1 - \sin\theta_2)}\right)\sigma_2\sigma_1 \\ \left(1 + e^{j2\pi(\sin\theta_2 - \sin\theta_1)}\right)\sigma_1\sigma_2 & 2\sigma_2\sigma_2 \end{bmatrix}$$

行列式不为零



来波方向: 10° , 30° , 60°



1. 相关性
2. 相干源问题
3. 空间平滑法
4. 空间平滑法去相关性能分析



相干源情况： \mathbf{R}_S 不满秩，空间平滑得到的 $\tilde{\mathbf{R}}_S$ 满秩。

另一种极端情况： P 个不相关源，则 \mathbf{R}_S 的非对角元素均为零。

问题： 在相干源情况下，空间平滑后 $\tilde{\mathbf{R}}_S$ 的非对角元素的模的减小程度如何？

$$\tilde{\mathbf{R}}_S = \frac{1}{L} \sum_{l=1}^L \mathbf{D}^{(l-1)} \mathbf{R}_S \mathbf{D}^{-(l-1)}$$

其中，第 i 行 j 列的元素为：



$$\begin{aligned}\tilde{r}_S(i, j) &= \frac{1}{L} \sum_{l=1}^L r_S(i, j) e^{j(l-1)\pi \sin \theta_i} e^{-j(l-1)\pi \sin \theta_j} \\ &= r_S(i, j) \frac{1}{L} \sum_{l=1}^L e^{j(l-1)\pi \sin \theta_i} e^{-j(l-1)\pi \sin \theta_j} \\ &= r_S(i, j) F(\theta_i, \theta_j)\end{aligned}$$

$$|\tilde{r}_S(i, j)| = |r_S(i, j)| |F(\theta_i, \theta_j)|$$



$$\left| F(\theta_i, \theta_j) \right| = \left| \frac{\sin \pi L \frac{\sin \theta_i - \sin \theta_j}{2}}{L \sin \pi \frac{\sin \theta_i - \sin \theta_j}{2}} \right| \leq 1 \Rightarrow \left| \tilde{r}_S(i, j) \right| \leq \left| r_S(i, j) \right|$$

- 当 $i = j$ 时, $\left| \tilde{r}_S(i, j) \right| = \left| r_S(i, j) \right|$ 为对角元素;
- 当 $i \neq j$ 时, $\left| \tilde{r}_S(i, j) \right| < \left| r_S(i, j) \right|$ 非对角元素, 减小了相关性;

可知: 去相关能力依赖于 L 和信源波达角的正弦差 $(\sin \theta_i - \sin \theta_j)$



1. L 越大去相关能力越强。

2. 当 $\Delta\theta_{ij} = \theta_i - \theta_j$ 一定时, $\sin\theta_i - \sin\theta_j \approx \Delta\theta_{ij} \cos\theta_i$

■ $\theta_i \rightarrow 0^\circ$ 时, $\sin\theta_i - \sin\theta_j$ 较大, 去相关效果较好;

■ $\theta_i \rightarrow 90^\circ$ 时, $\sin\theta_i - \sin\theta_j$ 较小, 去相关效果不明显。



L 越大去相关能力越强。

M 元等距线阵 $L = M - K + 1$

M 固定： L 增大，则 K 减小，即子阵孔径减小，导致可分辨的信源个数减少。

改进方法： 在 M 和 K 固定情况下，设法提高平滑次数 L 。

正反向滑动子阵。